

Ce que signifie la vraisemblance : d'un produit brut à un score borné et comparable

Warith Harchaoui

Été 2026

Résumé


Cette note dérive, à partir des principes de base, une seule idée utilisée à travers la statistique, la théorie de l'information et l'apprentissage automatique : lire la vraisemblance non comme le produit brut par lequel tout traité classique commence, mais comme une *moyenne* exponentiée de log-densités, $L := \exp(\mathbb{E}[\ln p])$. Cette reformulation est inhabituelle : presque aucune référence classique ne définit la vraisemblance ainsi. Cette note explique précisément pourquoi elle se justifie : une identité exacte qui la relie au produit classique, une lecture directe en théorie de l'information (inégalité de Jensen, entropie de Shannon, un raffinement indexé par une température emprunté à la mécanique statistique à l'équilibre), deux résultats asymptotiques classiques (les grandes déviations de Cramér et la martingale de Wald) qui décrivent exactement le comportement à long terme de cette quantité, et un compte rendu précis de L comme estimateur statistique, biais et variance compris, ainsi qu'une preuve que le produit brut qu'il remplace n'estime rien de fixe du tout. Deux cas travaillés, un modèle de classification catégorielle et un modèle de régression sous bruit gaussien, montrent la même construction retomber sur l'inverse d'une mesure d'erreur familière dans les deux cas, la perplexité dans le premier, l'erreur quadratique moyenne racine dans le second. La propre note de mathématiques d'`elbow-helper`, `ELBOW-fr.tex`, construit ses critères de sélection de modèle gaussiens (BIC, mBIC, ICL) sur le socle dérivé ici plutôt que de le rederiver. Les citations suivent la même convention de sourçage que `ELBOW-fr.tex` : chaque affirmation précise s'il s'agit d'une citation vérifiée, d'une citation rapportée par une source secondaire, ou d'une construction propre à cette note.

Table des matières

1	La notion	3
2	Ce que le nombre signifie	3
3	Pourquoi une moyenne, pas une somme : grandes déviations et martingales	5
4	Deux cas travaillés	7
4.1	Classification	7
4.2	Régression sous bruit gaussien	8
5	Une conclusion pratique : borner la vraisemblance	10

1 La notion

Les données désignent ici n paires (x_i, y_i) , une entrée x_i associée à un résultat y_i : une covariable pilotant une prédiction, une position pilotant la hauteur d'une courbe, ou rien du tout, x_i simplement absent, pour un modèle qui ne décrit jamais que y_i seul. Un unique modèle graphique couvre chaque cas que cette note utilise, θ et x_i alimentant une densité conditionnelle qui engendre y_i :



La *vraisemblance* désigne la densité jointe des résultats observés, lue comme une fonction du paramètre plutôt que des données : $L_{\text{brute}}(\theta) := \prod_{i=1}^n p(y_i | x_i, \theta)$, un simple produit de n termes, un par observation. C'est la définition par laquelle tout traité classique commence, celle de Bishop parmi les plus claires (Bishop, 2006). C'est aussi exactement la quantité qu'un facteur de Bayes ou un test du rapport de vraisemblance de Neyman-Pearson compare directement. Laissée sous forme de produit brut, c'est pourtant un mauvais matériau pour construire un score borné : n densités multipliées entre elles finissent soit par s'écraser vers zéro soit par exploser à mesure que n grandit, si bien que L_{brute} sur 40 points et L_{brute} sur 4 000 points ne sont pas des nombres qu'un même seuil pourrait jamais comparer ; le produit brut porte la taille de l'échantillon dans sa propre échelle.

Cette note s'écarte de cette convention dès maintenant et le dit franchement plutôt que de laisser cet écart implicite dans une formule : elle prend la vraisemblance *par observation* dès le départ, une moyenne *exponentiée* de log-densités plutôt qu'un produit brut,

$$L := \exp(\mathbb{E}[\ln p]) = L_{\text{brute}}^{1/n},$$

la moyenne géométrique des n densités individuelles, exactement la racine n -ième de L_{brute} , jamais un nombre différent, une forme différente du même nombre seulement. Presque aucune référence classique ne définit la vraisemblance ainsi. La raison n'est pas stylistique : diviser la somme de l'exposant par n avant de réexponentier est exactement ce qui transforme une quantité extensive, dont l'échelle dépend de la taille de l'échantillon, en une quantité intensive, dont l'échelle n'en dépend pas, le même geste que fait la théorie de l'information quand elle travaille avec la *perplexité*, une *moyenne* exponentiée de log-probabilité plutôt qu'une probabilité jointe brute (rendu explicite à la section 4).

2 Ce que le nombre signifie

Avant toute machinerie asymptotique, L a une lecture directe qui mérite qu'on s'y arrête. Par l'inégalité de Jensen, $\ln$ étant concave, $L = \exp(\mathbb{E}[\ln p]) \leq \mathbb{E}[p]$ toujours : la moyenne géométrique sur laquelle repose cette note ne dépasse jamais la moyenne arithmétique de ces mêmes densités, avec égalité seulement quand p est constante sur les observations.

Pour un p discret sur K catégories, prenons l'espérance sous p lui-même plutôt que sous les données : $\exp(\mathbb{E}_{y \sim p}[\ln p_y]) = \exp(-H(p))$, l'entropie de Shannon (MacKay, 2003) lue comme une probabilité plutôt que comme un compte de bits. Cela reste dans $[1/K, 1]$: égal à $1/K$ quand p est uniforme sur les K catégories, montant vers 1 à mesure que p se concentre sur l'une d'elles. Lue ainsi,

$\exp(-H(p))$ est une probabilité typique, ou effective. Son inverse $\exp(H(p))$ est le nombre effectif de catégories plausibles : $\exp(H(p)) \approx 4$ signifie une incertitude comparable à un choix équiprobable parmi quatre.

Une lecture en température. Cette borne admet un raffinement à un paramètre qui mérite d’être rendu précis plutôt que simplement évocateur. Pour $\beta > 0$, définissons la famille inclinée par puissance $p_\beta(y) := p(y)^\beta / Z(\beta)$, $Z(\beta) := \int p(y)^\beta dy$ (ou $\sum_y p(y)^\beta$ dans le cas discret) : une véritable famille exponentielle, où β joue le rôle que Gibbs attribue à la température inverse face à l’« énergie » $-\ln p(y)$. C’est exactement l’objet que décrit le dictionnaire grandes déviations / mécanique statistique : $\ln Z(\beta)$ est une énergie libre mise à l’échelle, β sa température inverse, et la relation de transformée de Legendre qu’utilise l’argument de Cramér de la section 3 pour la fonction de taux est, terme à terme, celle qui relie énergie libre et entropie en mécanique statistique à l’équilibre (Touchette, 2009). Dériver en $\beta = 1$, où $p_\beta = p$, redonne L lui-même : $\frac{d}{d\beta} \ln Z(\beta) \big|_{\beta=1} = \mathbb{E}_p[\ln p] = \ln L$, si bien que L est une dérivée d’une énergie libre, évaluée à une température précise. L’entropie de Shannon ci-dessus est elle-même la limite $\beta \rightarrow 1$ de l’entropie de Rényi $H_\beta(p) := \ln Z(\beta)/(1-\beta)$, un fait standard vérifiable directement à partir des définitions ci-dessus.

Les deux extrêmes de β se lisent exactement comme les deux extrêmes de température, rendus précis plutôt que laissés à l’image. Quand $\beta \rightarrow 0^+$, chaud et maximalelement agité, p_β s’aplatit vers l’uniforme sur le support de p quelle que soit l’allure de p lui-même : $Z(\beta) \rightarrow K$ dans le cas à K catégories, si bien que $\exp(-H_\beta(p)) \rightarrow 1/K$, exactement le plancher dérivé plus haut. Quand $\beta \rightarrow \infty$, froid et gelé, p_β s’effondre sur le mode propre de p : $\exp(-H_\beta(p)) \rightarrow \max_k p_k$, la probabilité de la catégorie la plus probable, un plafond plus serré et dépendant de p que la borne supérieure lâche de 1 (atteinte seulement dans la limite dégénérée où p lui-même est déjà une masse ponctuelle). Vérifié numériquement sur $p = (0,5, 0,3, 0,15, 0,05)$: $\exp(-H_\beta(p))$ passe de $0,25 = 1/4$ quand $\beta \rightarrow 0$ à $0,5 = \max_k p_k$ quand $\beta \rightarrow \infty$, de façon monotone, en passant par $\exp(-H(p)) \approx 0,32$ à $\beta = 1$. Les deux extrêmes familiers de l’eau à pression atmosphérique, le gel à 0°C et l’ébullition à 100°C , illustrent physiquement exactement cette forme, un système fixe balayé d’une phase ordonnée, à faible entropie, vers une phase désordonnée, à forte entropie, à mesure qu’un paramètre analogue à une température inverse parcourt sa plage, non une correspondance numérique : rien ici n’affirme que $\beta = 0$ ou $\beta = \infty$ se situent littéralement à ces deux valeurs Celsius, seulement que le mécanisme qualitatif et sa comptabilité exacte en transformée de Legendre sont ceux que la mécanique statistique à l’équilibre a déjà établis.




FIGURE 1 – À gauche : le diagramme en barres ci-dessus, $p = (0,5, 0,3, 0,15, 0,05)$, avec sa moyenne géométrique $\exp(\mathbb{E}[\ln p]) \approx 0,319$ et sa moyenne arithmétique $\mathbb{E}[p(Y)] \approx 0,365$ marquées, l'inégalité de Jensen rendue visible par deux lignes horizontales plutôt que laissée en simple formule. À droite : $\exp(-H_\beta(p))$ balayé sur β , chaud à gauche, froid à droite, se déplaçant de façon monotone du plancher $1/K = 0,25$ au plafond $\max_k p_k = 0,5$, avec $\beta = 1$, le L propre de cette note, marqué là où il se situe sur ce trajet.

3 Pourquoi une moyenne, pas une somme : grandes déviations et martingales

Deux résultats classiques disent que ce n'est pas une simple remise à l'échelle de confort. Notons $Z_i := \ln p(y_i | x_i, \theta)$ la log-densité par observation, si bien que $L = \exp(\frac{1}{n} \sum_i Z_i)$, une moyenne empirique exponentiée. D'abord, la relation exacte que cela redonne avec L_{brute} : $L^n = \exp(\sum_i Z_i) = \prod_i p(y_i | x_i, \theta) = L_{\text{brute}}(\theta)$. Prendre la racine n -ième puis réexponentier une moyenne ne perd aucune information par rapport au produit brut ; c'est le même nombre, à une racine n -ième près, désormais exprimé sous la seule forme dont le comportement à grand échantillon est compris.

Le théorème de Cramér (Cramér, 1938), le résultat fondateur de la théorie des grandes déviations, dit qu'une moyenne empirique i.i.d. comme $\frac{1}{n} \sum_i Z_i$ fait plus que converger vers $\mathbb{E}[Z]$, la garantie de la loi des grands nombres : la probabilité qu'elle s'écarte de cette limite de plus qu'une quantité fixe décroît exponentiellement en n , à un taux fixé par une fonction de taux convexe, la transformée de Legendre de la fonction génératrice des cumulants de Z . Travailler d'abord avec la moyenne, plutôt qu'avec le produit brut L^n dont elle n'est qu'une racine n -ième, expose cette structure exponentielle au lieu de l'enfouir dans un nombre déjà multiplié.

Chernoff (Chernoff, 1952) spécialise exactement cette machinerie à la décision entre deux densités p_0, p_1 à partir de n tirages i.i.d., dans le cadre symétrique où les deux hypothèses portent chacune un a priori et où un même test minimise la probabilité totale d'erreur (bayésienne) plutôt qu'un type d'erreur à niveau fixé de l'autre : la meilleure probabilité d'erreur totale qu'un tel test puisse atteindre décroît en $\exp(-n C(p_0, p_1))$, où l'information de Chernoff $C(p_0, p_1) := -\min_{\lambda \in [0,1]} \ln \int p_0^\lambda p_1^{1-\lambda}$ est, structurellement, une moyenne exponentiée de log de plus, cette fois une intégrale sur l'espace des observations plutôt qu'une moyenne sur les observations elles-mêmes. C'est une question différente de celle à laquelle répond le lemme de Chernoff-Stein, qui fixe la probabilité d'un type d'erreur et

demande à quelle vitesse l'autre peut être réduite, ce qui conduit à la divergence de Kullback-Leibler plutôt qu'à l'information de Chernoff ; les deux résultats sont souvent confondus précisément parce qu'ils portent tous deux le nom de Chernoff.

Le même produit courant a une seconde vie, complémentaire, en tant que *processus* plutôt que nombre unique. Définissons le processus de rapport de vraisemblance $\Lambda_t := \prod_{i=1}^t p_1(y_i)/p_0(y_i) = \exp\left(\sum_{i=1}^t \ln[p_1(y_i)/p_0(y_i)]\right)$ sur les t premières observations. Sous p_0 , Λ_t est une martingale positive, $\mathbb{E}_{p_0}[\Lambda_t \mid \mathcal{F}_{t-1}] = \Lambda_{t-1}$, le fait sur lequel Wald (Wald, 1945) a bâti le Sequential Probability Ratio Test : un seuil franchi par Λ_t à un instant d'arrêt qui dépend des données continue de contrôler le taux d'erreur du test, par le théorème d'arrêt optionnel, la garantie qu'un test à n fixé obtient automatiquement et qu'un arrêt naïf n'obtient pas. Cette garantie exige cependant deux densités entièrement spécifiées p_0 et p_1 , une exigence que tout problème séquentiel ne peut pas satisfaire ; le test séquentiel propre d'**elbow-helper** (ELBOW-fr.tex, la section du test séquentiel, **sec:fwer**) en est exactement un exemple, son alternative à chaque étape étant un point de rupture supplémentaire composite et le mieux ajusté plutôt qu'une seconde densité fixe, ce pourquoi elle se calibre contre un nul de permutation plutôt que contre la borne martingale classique de Wald.

Deux questions distinctes sur L comme estimateur. Tout ce qui a été calculé jusqu'ici, L compris, provient d'un échantillon fini, si bien que deux questions distinctes méritent d'être séparées proprement plutôt que de laisser l'une se cacher dans l'autre. D'abord : le L d'échantillon que cette note calcule sur n observations réelles est-il un bon estimateur de la valeur de population vers laquelle il converge quand $n \rightarrow \infty$? Ensuite : le produit brut sans racine L_{brute} , le L propre de cette note avant que la racine n -ième ne soit prise, estime-t-il cette même valeur de population ? Fixons d'abord la cible. Soient $(X_1, Y_1), \dots, (X_n, Y_n)$ tirés i.i.d. selon la vraie distribution jointe des données q , et p_θ un modèle candidat pour $p(y \mid x)$. Quand $n \rightarrow \infty$, le L propre de cette note est construit pour converger vers un seul nombre fixe,

$$L_\infty := \exp(\mu_Z), \quad \mu_Z := \mathbb{E}_q[\ln p_\theta(Y \mid X)],$$

non une quantité aléatoire : μ_Z est une espérance ordinaire sous la vraie q , un simple nombre une fois p_θ et q fixés. Deux quantités d'échantillon différentes peuvent maintenant être comparées à cette même cible.

La première est le L propre de cette note, calculé sur n paires observées : $\hat{L}_n := \exp(\bar{Z}_n)$, $\bar{Z}_n := \frac{1}{n} \sum_i Z_i$, $Z_i := \ln p_\theta(Y_i \mid X_i)$. $\bar{Z}_n$ est exactement sans biais pour μ_Z , si bien que $\hat{L}_n$ est un authentique estimateur de L_∞ , quoique pas sans biais : $\exp$ est convexe, si bien que l'inégalité de Jensen, la même que la section 2 utilise pour borner L lui-même, donne $\mathbb{E}[\hat{L}_n] \geq L_\infty$ toujours. La méthode delta rend la taille de ce biais vers le haut explicite,

$$\mathbb{E}[\hat{L}_n] = L_\infty \left(1 + \frac{\sigma_Z^2}{2n} + O(n^{-2})\right), \quad \text{Var}[\hat{L}_n] = L_\infty^2 \frac{\sigma_Z^2}{n} + O(n^{-2}), \quad \sigma_Z^2 := \text{Var}_q[Z],$$

les deux s'annulant quand $n \rightarrow \infty$: $\hat{L}_n$ est convergent, en fait $\sqrt{n}$ -convergent et asymptotiquement normal, $\sqrt{n}(\hat{L}_n - L_\infty) \rightarrow \mathcal{N}(0, L_\infty^2 \sigma_Z^2)$ en distribution, son biais s'annulant au même rythme $O(1/n)$ que sa variance. (Une simulation Monte-Carlo avec $p_\theta = q$ bien spécifié, 10^5 répliques par taille d'échantillon $n \in \{5, \dots, 1000\}$, retrouve les deux formules de près à chaque n testé, une vérification propre à cette note plutôt qu'une affirmation nécessitant une citation.)

La seconde candidate est le produit brut que cette note a rejeté dès l'ouverture, $L_{\text{brute}} := \prod_i p_\theta(Y_i \mid X_i) = \hat{L}_n^n = \exp(n \bar{Z}_n)$. Est-il, lui aussi, un estimateur de L_∞ ? Son espérance répond directement à la question :

$$\mathbb{E}[L_{\text{brute}}] = (\mathbb{E}_q[e^Z])^n = \exp(n \Lambda(1)), \quad \Lambda(u) := \ln \mathbb{E}_q[e^{uZ}],$$


où Λ est exactement la fonction génératrice des cumulants sur laquelle repose l'argument de Cramér ci-dessus. Pour que $\mathbb{E}[L_{\text{brute}}]$ converge vers L_∞ , ou vers quoi que ce soit de fixe, il faudrait que $\Lambda(1)$ soit exactement nul, une condition limite sans raison de tenir pour un p_θ générique. En son absence, $\mathbb{E}[L_{\text{brute}}]$ décroît vers 0 ou explose vers ∞ exponentiellement vite en n . L_{brute} n'est pas un estimateur biaisé ou bruité de L_∞ : ce n'en est pas un du tout, la version précise et quantitative de l'observation d'ouverture de la section 1, selon laquelle L_{brute} sur 40 points et sur 4000 points ne sont pas des nombres qu'un même seuil pourrait jamais comparer.

4 Deux cas travaillés

La même construction, une moyenne exponentiée de log-densité, retombe sur l'inverse d'une mesure d'erreur familière dans les deux cadres que l'apprentissage automatique ajuste le plus souvent : un modèle de classification catégorielle et un modèle de régression sous bruit gaussien.

4.1 Classification

Le modèle génératif d'un classifieur est le même modèle graphique que celui de la section 1, spécialisé à un résultat catégoriel : x_i et θ fixent un vecteur de probabilités sur K classes ; y_i en est tiré.



Si Y est la vraie classe et qu'un modèle prédit $p(Y | X)$, $\exp(\mathbb{E}_{(X,Y)}[\ln p(Y | X)]) = \exp(-\text{CE})$ est exactement la probabilité géométrique moyenne que le modèle attribue à la bonne classe, une lecture qu'une entropie croisée brute en nats n'offre pas directement. Une entropie croisée de 0,693 nats, $\ln 2$, devient $\exp(-0,693) \approx 0,5$: un modèle à peu près aussi confiant, sur la bonne classe, qu'un tirage à pile ou face. De façon équivalente, $\exp(\text{CE})$ est la *perplexité* que le modèle attribue à la vraie classe, le nombre effectif de classes parmi lesquelles il hésite du point de vue de sa confiance ; une perplexité proche de 1 signale un modèle confiant et bien calibré, une perplexité proche de K (le nombre de classes) ne vaut pas mieux qu'un tirage uniforme.

Reprenons l'exemple $p = (0,5, 0,3, 0,15, 0,05)$ déjà tracé en figure 1, désormais lu comme les probabilités prédites par un modèle pour un exemple donné, la classe 1 étant le vrai label. L'entropie croisée du modèle sur cet exemple unique est $\text{CE} = -\ln p_1 = -\ln 0,5 \approx 0,693$ nats, exactement le cas du tirage à pile ou face ci-dessus : le modèle n'accorde à la vraie classe qu'une chance sur deux, alors même que c'est sa classe la plus probable. Moyenné sur de nombreux exemples plutôt que lu sur un seul, ce même $\exp(-\text{CE})$ devient la probabilité géométrique moyenne que le modèle attribue à la classe qui s'avère vraie à chaque fois. Le panneau de droite de la figure 1 est exactement cette machine de moyennage transformée en cadran : $\beta = 1$ est l'entropie croisée ordinaire, non inclinée, lue ci-dessus, $\beta \rightarrow 0$ adoucit chaque prédiction vers une confiance uniforme sur les K classes indépendamment de l'avis propre du modèle, tandis que $\beta \rightarrow \infty$ durcit chaque prédiction vers sa classe la plus probable, un bouton de température transformant un classifieur probabiliste en quelque chose de plus proche d'un simple $\arg \max$ à mesure qu'il refroidit.

La figure 2 fait passer cet exemple unique, choisi à la main, à une véritable simulation : 45 points tirés de 3 classes qui se chevauchent, chacun se voyant attribuer une probabilité pour sa propre vraie classe par un simple modèle softmax fondé sur la distance au centroïde. Certains points sont profondément ancrés dans le territoire de leur classe et obtiennent un score élevé ; d'autres se trouvent près d'une frontière entre deux classes et obtiennent un score bas, le modèle étant réellement incertain quant à la bonne étiquette. L est la moyenne géométrique de ces 45 probabilités individuelles, pas un résumé arbitraire d'entre elles : le panneau de droite les trie du plus bas au plus haut et marque exactement où tombe cette moyenne géométrique, visiblement plus proche de la masse des scores bas qu'une moyenne arithmétique ne le serait, la même attraction vers les pires cas que l'inégalité de Jensen avait déjà prédite.





FIGURE 2 – À gauche : 45 exemples simulés issus de 3 classes qui se chevauchent (les anneaux pointillés marquent les centroïdes générateurs), la taille du point montrant la probabilité du modèle pour la vraie classe propre à chaque exemple, petite près d'une frontière de classe, grande profondément dans le territoire d'une classe. À droite : ces mêmes 45 probabilités triées du plus bas au plus haut, avec leur moyenne géométrique, le L de cette note, marquée.

Un simple scalaire, pourtant, que ce soit CE, $\exp(-\text{CE})$ ou une perplexité, ne répond jamais qu'à « à quel point confiant, en moyenne », jamais à « à quelle fréquence effectivement juste ». Un modèle peut se tromper avec assurance, en attribuant une forte probabilité à une classe incorrecte. CE pénalise justement cet excès de confiance plus durement qu'une petite incertitude honnête ne le serait, la même asymétrie qu'une règle de score propre est construite pour avoir : parier 99 % sur une classe qui s'avère fausse coûte bien plus de nats que parier 60 % ne le ferait jamais. Cette asymétrie, plus que le simple niveau de confiance moyen, explique pourquoi c'est l'entropie croisée, et non l'exactitude brute de classification, que la descente de gradient ajuste dans pratiquement tout classifieur moderne.

4.2 Régression sous bruit gaussien

Soit $y_i = f(x_i; \theta) + \varepsilon_i$ avec ε_i i.i.d. $\mathcal{N}(0, \sigma^2)$, f une fonction de régression quelconque et θ ses paramètres, la densité conditionnelle générique de la section 1 spécialisée à une famille particulière :



$$p(y_i | x_i, \theta) = (2\pi\sigma^2)^{-1/2} \exp\left(-\frac{(y_i - f(x_i; \theta))^2}{2\sigma^2}\right) \quad (1)$$

si bien que, en notant $\text{MSE}(\theta) := \frac{1}{n} \sum_i (y_i - f(x_i; \theta))^2$,

$$L(\theta, \sigma^2) = (2\pi\sigma^2)^{-1/2} \exp\left(-\frac{\text{MSE}(\theta)}{2\sigma^2}\right). \quad (2)$$

La figure 3 trace cette densité littéralement plutôt qu'en simples symboles : une petite cloche à quelques positions x choisies, chacune la densité conditionnelle $p(\cdot | x_i, \theta)$ couchée sur le côté, sa largeur fixée par σ et son centre suivant la droite ajustée. Le point marqué sur chaque cloche est la hauteur propre de cette courbe au point réellement observé, $p(y_i | x_i, \theta)$, haute là où l'ajustement tombe près de la donnée, basse sinon. L n'est rien de plus que la moyenne géométrique de ces hauteurs prise sur chaque observation, pas seulement les quatre marquées, l'exact pendant continu des barres triées de la figure 2 : un ajustement proche presque partout affiche surtout des hauteurs élevées et un L grand, un ajustement qui s'égare affiche quelques hauteurs basses qui tirent la moyenne géométrique vers le bas, un mauvais écart faisant plus de dégâts sur une moyenne géométrique que sur une moyenne arithmétique, la même asymétrie que l'inégalité de Jensen de la section 2 signalait déjà.

À la variance de maximum de vraisemblance $\hat{\sigma}^2 = \text{MSE}(\theta)$,

$$\exp(\mathbb{E}[\ln p]) = \frac{1}{\sqrt{2\pi e} \sqrt{\text{MSE}(\theta)}}, \quad (3)$$

l'inverse de l'erreur quadratique moyenne racine à une constante universelle $\sqrt{2\pi e}$ près, l'exact pendant continu de la lecture inverse-perplexité de la section 4.1 : dans les deux cas, $\exp(\mathbb{E}[\ln p])$ est l'inverse d'une mesure d'erreur propre à la tâche de prédiction, la perplexité pour une prédiction catégorielle, l'erreur quadratique moyenne racine pour une prédiction continue. Ce n'est pas une coïncidence. En notant $\ell := \ln L$ et, suivant la convention des critères d'information, $\text{PPL} := \exp(-2\ell)$, l'identité $\exp(\mathbb{E}[\ln p]) = 1/\sqrt{\text{PPL}}$ tient en général, que le modèle soit gaussien ou non, une conséquence directe des deux définitions plutôt qu'une propriété propre à l'un ou l'autre cas travaillé. La propre `ELBOW-fr.tex` d'`elbow-helper` pousse cette instanciation plus loin : f y parcourt les droites simples, les lignes brisées et les lignes brisées à k segments. Le PPL y devient un score véritablement borné et ancré sur un pire cas, plutôt que laissé comme une simple lecture inverse-RMSE.




FIGURE 3 – Données de régression synthétiques, $y = 2 + 0,5x + \varepsilon$, $\varepsilon \sim \mathcal{N}(0, 0,9^2)$, avec la droite ajustée et quatre courbes de densité conditionnelle $p(\cdot | x, \theta)$ tracées à des positions x choisies. Chaque point marque la hauteur propre de cette courbe à la valeur réellement observée là. L est la moyenne géométrique de chaque hauteur, pas seulement les quatre marquées : haute là où l’ajustement tombe près de la donnée, basse là où un point s’éloigne du centre de la courbe.

5 Une conclusion pratique : borner la vraisemblance

Chaque quantité que cette note a construite, CE, ℓ , PPL, est une remise à l’échelle du même nombre sous-jacent. Chacune de ces remises à l’échelle partage le même premier problème : prise brute, elle n’a pas de plafond, si bien qu’aucun seuil unique dessus ne signifie la même chose d’un ajustement à l’autre. Y remédier demande de s’ancrer contre un pire cas réel et atteignable plutôt que contre un cas arbitraire ou inaccessible, un geste que la classification ne doit faire qu’une fois et que la régression doit faire deux fois, pour une raison qui mérite d’être précisée plutôt que simplement évoquée.

Le $\text{CE}(\theta) \geq 0$ de la classification a déjà un plancher propre : nul exactement pour une prédiction parfaitement confiante et correcte, rien de spécial à faire pour l’atteindre. Le balayage en température de la section 2 a déjà nommé le plafond naturel contre lequel s’ancrer. Quand $\beta \rightarrow 0$, chaud et maximale agité, la confiance de n’importe quel modèle s’aplatit vers l’uniforme sur les K classes, indépendamment de ce qu’il croyait réellement. Un modèle qui prédit uniformément obtient exactement $\text{CE} = \ln K$ sur n’importe quelle vraie classe, la seule valeur d’entropie croisée qui ne dépend pas de la classe qui s’avère juste. Ce n’est pas une référence arbitraire : c’est ce que coûte, en nats, le refus d’utiliser la moindre information propre au modèle, quelle que soit l’étiquette, si bien que

$$Q_{\text{classif}}(\theta) := 1 - \frac{\text{CE}(\theta)}{\ln K}$$

vaut 1 pour un modèle parfaitement confiant et correct, 0 pour un modèle qui ne vaut pas mieux qu'un tirage uniforme, et une valeur négative pour un modèle activement trompeur, confiant à tort plus souvent que confiant à raison, un signal que cette note ne voit aucune raison de masquer en l'écrétant.

La log-vraisemblance propre à la régression n'a pas un tel plancher. C'est le second problème, distinct du plafond que les deux cas partagent. Une densité continue peut dépasser 1, si bien que profiler σ^2 à sa valeur la mieux soutenue $\hat{\sigma}^2 = \text{MSE}(\theta)$ envoie $\ell(\theta, \hat{\sigma}^2)$ vers $+\infty$, pas vers un 0 propre, exactement à l'ajustement parfait, la dégénérescence classique de la vraisemblance qui justifie l'existence même du BIC. Exponentier répare d'abord cela : $\text{PPL}(\theta) := \exp(-2\ell(\theta, \hat{\sigma}^2)) = 2\pi e \cdot \text{MSE}(\theta) \geq 0$, nul exactement à l'ajustement parfait, toujours non borné au-dessus mais partant désormais d'un plancher sur lequel construire. La propre `ELBOW-fr.tex` d'`elbow-helper` fournit le second geste, le plafond : non une formule mais un véritable pire cas tiré des données elles-mêmes, le seul point *observé* y_{bad} le plus difficile à partir duquel prédire tous les autres, donnant à $\text{MSE}_{\text{worst}}$ exactement le rôle que joue $\ln K$ ci-dessus,

$$Q_{\text{reg}}(\theta) := 1 - \frac{\text{MSE}(\theta)}{\text{MSE}_{\text{worst}}} = 1 - \frac{\text{PPL}(\theta)}{\text{PPL}_{\text{worst}}},$$

les deux rapports étant égaux parce que PPL et MSE portent la même constante $2\pi e$ au numérateur comme au dénominateur.

Deux pires cas différents répondent à la même question dans les deux seules façons que permet le modèle génératif propre à cette note. Un classifieur à K catégories a une alternative fixe, indépendante de l'étiquette, intégrée à sa propre structure, le tirage uniforme, et n'a jamais besoin de regarder les données pour en trouver une. Un régresseur continu n'a pas une telle alternative intégrée : rien dans la famille du modèle seule ne dit à quoi ressemble une mauvaise prédiction, si bien que le pire cas doit être emprunté à l'échantillon même que le modèle essaie d'ajuster. Une fois cette asymétrie prise en compte plutôt que masquée, CE et MSE, des nombres qui n'avaient de sens que face à une autre exécution du même modèle sur les mêmes données, deviennent Q_{classif} et Q_{reg} , des nombres qui signifient la même chose sur n'importe quel jeu de données, de n'importe quelle taille, dans l'une ou l'autre langue dans laquelle cette note est écrite.

Références

- Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.
- Herman Chernoff. A measure of asymptotic efficiency for tests of a hypothesis based on the sum of observations. *The Annals of Mathematical Statistics*, 23(4) :493–507, 1952.
- Harald Cramér. Sur un nouveau théorème-limite de la théorie des probabilités, 1938. Actualités Scientifiques et Industrielles, no. 736, Colloque consacré à la théorie des probabilités.
- David J. C. MacKay. *Information Theory, Inference, and Learning Algorithms*. Cambridge University Press, 2003.
- Hugo Touchette. The large deviation approach to statistical mechanics. *Physics Reports*, 478(1-3) : 1–69, 2009.
- Abraham Wald. Sequential tests of statistical hypotheses. *The Annals of Mathematical Statistics*, 16(2) :117–186, 1945.